Detecció de Llenguatge Tòxic en Textos Curts

Maria Muñoz Cabestany
1668438

Treball Final de Grau



Tutor: Jordi González Sabaté
Departament de Ciències de la Computació

Grau en Matemàtica Computacional i Analítica de Dades

Facultat de Ciències
Universitat Autònoma de Barcelona

Curs 2025-2026
Bellaterra
19 de juny de 2026

Resum: *En aquest treball s'estudia la detecció automàtica de llenguatge tòxic en textos curts mitjançant models clàssics de machine learning basats en representacions Bag-of-Words, TF-IDF i n-grams. Es comparen diferents classificadors, concretament Logistic Regression, Linear SVM, Multinomial Naive Bayes, Complement Naive Bayes i Bernoulli Naive Bayes, juntament amb diverses estratègies de millora. Finalment, se selecciona un model que combina n-grams de paraula i de caràcter amb l'ajust del llindar de decisió, assolint un F1-macro de 0.922 en el dataset principal i de 0.691 en Jigsaw. Els resultats mostren un rendiment elevat en avaluació in-domain, però una pèrdua de rendiment en avaluació out-of-domain deguda al domain shift i a diferències en els criteris d'etiquetatge entre datasets. L'anàlisi qualitativa identifica errors associats a artefactes del dataset, polisèmia, cobertura de vocabulari, longitud i estil discursiu. Finalment, les proves amb sarcasme evidencien les limitacions del model per interpretar ironia i llenguatge no literal. El codi font desenvolupat per a aquest projecte està disponible a: repositori del codi font.*

Paraules clau: *detecció de llenguatge tòxic, processament del llenguatge natural, classificació de text, machine learning, domain shift, sarcasme.*

Abstract: *This work studies automatic toxic language detection in short texts using classical machine learning models based on Bag-of-Words, TF-IDF and n-gram representations. Several classifiers are compared, specifically Logistic Regression, Linear SVM, Multinomial Naive Bayes, Complement Naive Bayes and Bernoulli Naive Bayes, together with different improvement strategies. Finally, a model combining word and character n-grams with decision-threshold adjustment is selected, achieving a macro F1-score of 0.922 on the main dataset and 0.691 on Jigsaw. The results show high performance in in-domain evaluation, but a performance drop in out-of-domain evaluation due to domain shift and differences in annotation criteria between datasets. The qualitative analysis identifies errors associated with dataset artefacts, polysemy, vocabulary coverage, text length and discourse style. Finally, sarcasm-based tests highlight the model's limitations in interpreting irony and non-literal language. The source code developed for this project is available at: source code repository.*

Keywords: *toxic language detection, natural language processing, text classification, machine learning, domain shift, sarcasm.*

Índex

1 Introducció **4**

2 Objectius **4**
2.1 Objectiu principal 4
2.2 Objectius específics 4

3 Estat de l'art **5**

4 Datasets **6**
4.1 Hate Speech and Offensive Language Dataset (Dataset principal) [1] 6
4.2 Jigsaw Toxic Comment Classification Challenge [2] 6
4.3 Datasets per a l'anàlisi de sarcasme 7
4.3.1 Balanced Sarcasm Dataset [4] 7
4.3.2 The Best Sarcasm Annotated Dataset in Spanish [3] 7

5 Metodologia **7**
5.1 Divisió del conjunt de dades 7
5.2 Preprocessament del text 7
5.3 Anàlisi exploratòria de dades del dataset principal 8
5.4 Tokenització i representació del text 9
5.5 Models de classificació 10
5.6 Cerca d'hiperparàmetres 10
5.7 Avaluació del rendiment 11

6 Resultats base **11**
6.1 Resultats en el dataset principal 11
6.2 Resultats en el dataset Jigsaw 11
6.3 Anàlisi dels resultats 12
6.3.1 Anàlisi de la definició de toxicitat 12

7 Millores i experiments **13**
7.1 Pesos de classe 13
7.2 Ajust del llindar de decisió 13
7.3 N-grams de caràcter 14
7.4 Combinació de millores 14
7.5 Eliminació de stopwords 14
7.6 Adaptació de domini amb Jigsaw (experiment controlat) 15
7.7 Model final seleccionat 16
7.7.1 Anàlisi en el dataset principal 17
7.7.2 Anàlisi en el dataset Jigsaw 17

8 Anàlisi qualitativa **18**
8.1 Interpretabilitat del model basada en n-grams 18
8.2 Anàlisi d'errors 20
8.2.1 Artefactes del dataset i polisèmia 20
8.2.2 Cobertura de vocabulari i problemes out-of-vocabulary 21
8.2.3 Efecte de la longitud i de l'estil discursiu 22

9 Sarcasme com a conjunt de prova d'estrès **23**
9.1 Comparació amb exemples no sarcàstics classificats com a tòxics 24
9.2 Prova d'estrès addicional: sarcasme en castellà 25

10 Conclusions **26**

1 Introducció

Les xarxes socials i les plataformes digitals generen diàriament una gran quantitat de contingut textual, on els usuaris interactuen mitjançant comentaris, opinions i discussions. En aquest context, és freqüent la presència de llenguatge tòxic, ofensiu o fins i tot discurs d'odi, que pot tenir un impacte negatiu en les persones.

La detecció manual d'aquest tipus de contingut resulta inviable a gran escala, fet que ha impulsat el desenvolupament de tècniques automàtiques basades en el processament del llenguatge natural i el machine learning. No obstant això, aquesta tasca presenta diverses dificultats, ja que la toxicitat no sempre és explícita i pot dependre del context, del to o de fenòmens lingüístics complexos com el sarcasme o la ironia.

En aquest treball es planteja el problema de la detecció de llenguatge tòxic com una tasca de classificació binària, en què l'objectiu és determinar si un text curt pot ser considerat tòxic o no tòxic. Es posa especial èmfasi en l'ús de models lleugers i interpretables, amb la finalitat d'analitzar el comportament dels classificadors i entendre els factors que influeixen en les seves prediccions. A més, es presta una atenció particular a la capacitat de generalització dels models entre diferents datasets, ja que les definicions de toxicitat poden variar segons el domini. Aquesta variabilitat introdueix el fenomen conegut com a *domain shift*, que constitueix un dels principals reptes en aplicacions reals.

Finalment, el treball incorpora una anàlisi detallada dels errors dels models, amb especial interès en casos com el sarcasme, que poden posar a prova la robustesa dels models i evidenciar les seves limitacions.

2 Objectius

2.1 Objectiu principal

L'objectiu principal d'aquest treball és desenvolupar i analitzar un sistema de classificació binària de textos curts per a la detecció de llenguatge tòxic utilitzant models de machine learning lleugers i interpretables.

2.2 Objectius específics

Per assolir aquest objectiu general, es plantegen els següents objectius específics:

- Analitzar els datasets utilitzats, unificant els criteris d'etiquetatge per formular el problema com una classificació binària (tòxic/no tòxic) i estudiar l'impacte de les diferències en la definició de les etiquetes i en els criteris d'etiquetatge entre datasets.
- Implementar i comparar diversos models de classificació clàssics, com ara Logistic Regression, Support Vector Machines i Naive Bayes, utilitzant representacions textuals com Bag-of-Words i TF-IDF.
- Avaluar el rendiment dels models mitjançant tècniques de validació creuada i mètriques adequades per a dades desbalancejades, com l'F1-macro.
- Analitzar la capacitat de generalització dels models entrenats mitjançant la seva avaluació en un dataset diferent, amb l'objectiu d'estudiar l'impacte del *domain shift*.

- Analitzar possibles estratègies de millora basades en els resultats obtinguts i en les limitacions detectades durant l'avaluació.
- Realitzar una anàlisi qualitativa dels errors dels models, identificant patrons de fallada associats a fenòmens lingüístics complexos, com el sarcasme.

3 Estat de l'art

La detecció automàtica de llenguatge tòxic és una tasca consolidada dins del processament del llenguatge natural. Al llarg dels anys, la recerca en aquest àmbit s'ha articulat al voltant d'un conjunt de benchmarks que han permès comparar models i metodologies de forma sistemàtica. Entre aquests, el *Jigsaw Toxic Comment Classification Challenge* [2] destaca com un dels datasets més utilitzats en la literatura sobre classificació de comentaris tòxics. Aquest conjunt de dades està basat en comentaris de pàgines de discussió de Wikipedia i permet estudiar diferents formes de toxicitat en textos generats per usuaris.

Un altre conjunt de dades molt rellevant és el *Hate Speech and Offensive Language Dataset* [1], introduït per Davidson et al., basat en tweets de Twitter. Aquests dos conjunts de dades han estat seleccionats per a aquest treball i constitueixen la base dels experiments realitzats. La seva popularitat dins la literatura, juntament amb les diferències existents tant en el domini dels textos com en els criteris d'etiquetatge, els converteixen en una opció interessant per estudiar la generalització dels models en contextos amb *domain shift* i amb definicions de toxicitat diferents.

Sobre el dataset de Davidson et al., diversos treballs han analitzat quines representacions i models són més adequats per a la detecció de discurs d'odi i llenguatge ofensiu. El treball original [5] compara diferents característiques textuals, com n-grams, TF-IDF, etiquetes POS i sentiment, juntament amb models com Logistic Regression, Naive Bayes, arbres de decisió, Random Forest i Linear SVM. El millor model reportat obté un F1-score global de 0.90, però els resultats també evidencien dificultats importants per distingir correctament la classe de discurs d'odi, amb una precisió de 0.44 i un recall de 0.61 per a aquesta classe. Això mostra que el problema no consisteix només a detectar paraules ofensives, sinó també a interpretar el context en què apareixen. En la mateixa línia, Gaydhani et al. [6] mostren que les representacions basades en n-grams i TF-IDF, combinades amb models lineals com Logistic Regression, poden obtenir resultats molt competitius en classificació de textos curts, assolint una accuracy de test del 95.6% després de l'ajust d'hiperparàmetres.

Pel que fa al dataset Jigsaw, diversos treballs han explorat models més avançats basats en deep learning i representacions contextuals. Per exemple, Jessica et al. [8] proposen una arquitectura híbrida BERT-CNN que combina la capacitat contextual de BERT amb la detecció de patrons locals de les xarxes convolucionals. En una formulació binària del problema, on les diferents etiquetes de toxicitat es combinen en una única classe tòxica, el millor model reportat obté una accuracy i un F1-score de 0.9448, fet que mostra el potencial dels models contextuals quan es disposa de grans quantitats de dades etiquetades.

Més recentment, la recerca s'ha orientat cap a models de deep learning i transfer learning. Wei et al. [7] comparen un model Bi-LSTM amb arquitectures basades en models preentrenats com BERT, DistilBERT i GPT-2 sobre el dataset de Davidson. Els autors incorporen models preentrenats amb l'objectiu d'aprofitar representacions contextuals més riques que les representacions

lèxiques clàssiques, tot i que en els seus experiments el model Bi-LSTM ajustat assoleix una accuracy superior al 92%. Aquest tipus de treballs il·lustra l'evolució del camp cap a models amb major capacitat de capturar informació contextual. Tot i aquests avenços, la transferència entre dominis continua sent limitada, especialment quan varien la distribució dels textos i els criteris d'etiquetatge de la toxicitat.

Tot i l'existència de models més potents, en aquest treball s'ha optat per models clàssics basats en n-grams. Aquesta decisió es deu a la seva simplicitat, baix cost computacional i interpretabilitat, ja que permeten analitzar de manera directa quins patrons lèxics influeixen en les prediccions. Per aquest motiu, l'objectiu principal no és assolir l'estat de l'art en rendiment, sinó estudiar de manera controlada les limitacions dels models davant del *domain shift*, les diferències en els criteris d'etiquetatge i el sarcasme.

4 Datasets

En aquest treball s'han utilitzat diversos datasets amb l'objectiu de construir, entrenar i avaluar models de detecció de llenguatge tòxic, així com analitzar les seves limitacions davant de fenòmens lingüístics complexos. En particular, es diferencien dos tipus de datasets: els utilitzats per a l'entrenament i avaluació principal, i els utilitzats com a conjunt de prova d'estrès per a l'anàlisi d'errors.

4.1 Hate Speech and Offensive Language Dataset (Dataset principal) [1]

Aquest dataset constitueix el **conjunt de dades principal** del projecte i és l'únic utilitzat per a l'entrenament dels models principals. Així mateix, una partició independent del mateix conjunt s'empra per avaluar-ne el rendiment en un escenari *in-domain*. Conté aproximadament 24.000 textos curts (tweets) etiquetats en tres categories: *hate speech* (0), *offensive language* (1) i *neither* (2).

Per tal d'adaptar el problema a una classificació binària, s'ha realitzat una unificació de les etiquetes:

- Hate speech i offensive language: tòxic (1)
- Neither: no tòxic (0)

4.2 Jigsaw Toxic Comment Classification Challenge [2]

Aquest dataset s'utilitza com a conjunt de prova per avaluar la capacitat de generalització dels models entrenats. Conté aproximadament 160.000 comentaris procedents de pàgines de discussió de Wikipedia i, a diferència de l'anterior, conté comentaris més llargs i amb una estructura més formal. Cada comentari està anotat amb múltiples etiquetes de toxicitat. Pot estar etiquetat com *toxic, severe toxic, obscene, threat, insult* o *identity hate*, permetent capturar diferents formes i nivells de llenguatge ofensiu.

Per adaptar aquest dataset al marc del treball, s'ha realitzat una binarització de les etiquetes, considerant:

- Comentari tòxic (1): si està etiquetat com toxic o severe toxic.
- Comentari no tòxic (0): en cas contrari

Aquest dataset no s'utilitza per entrenar els models principals, sinó únicament per avaluar-los, excepte en l'experiment controlat d'adaptació de domini. Això permet estudiar el fenomen de *domain shift*, és a dir, la pèrdua de rendiment quan el model s'aplica a dades d'un domini diferent del d'entrenament.

4.3 Datasets per a l'anàlisi de sarcasme

Per tal d'analitzar el comportament dels models davant de fenòmens lingüístics complexos, s'han utilitzat datasets específics de sarcasme com a conjunt de prova d'estrès.

4.3.1 Balanced Sarcasm Dataset [4]

Aquest dataset està format per aproximadament 1,01 milions de registres procedents de comentaris de Reddit. Els textos estan escrits en anglès i presenten una distribució equilibrada entre comentaris sarcàstics i no sarcàstics. Aquesta característica el fa especialment útil per avaluar de manera controlada l'impacte del sarcasme en el comportament dels models.

4.3.2 The Best Sarcasm Annotated Dataset in Spanish [3]

Aquest dataset conté aproximadament 960 intervencions en castellà corresponents a dos episodis de *South Park*, amb doblatge llatinoamericà, i dos episodis d'*Archer*, amb doblatge d'Espanya. Els textos estan etiquetats segons la presència o absència de sarcasme i s'utilitzen com a prova d'estrès complementària per observar el comportament del model davant la combinació de llenguatge sarcàstic i canvi lingüístic, sense analitzar en profunditat l'efecte de l'idioma ni la capacitat multilingüe del model.

5 Metodologia

5.1 Divisió del conjunt de dades

El conjunt de dades principal s'ha dividit en dos subconjunts: entrenament (train) i test, utilitzant una partició fixa 80/20 estratificada per mantenir la proporció de classes. El conjunt de test s'ha mantingut separat de l'entrenament dels models i dels processos d'ajust. A partir del conjunt d'entrenament, s'ha realitzat validació creuada (*5-fold cross-validation*), que s'utilitza tant per a la selecció d'hiperparàmetres com per a l'ajust del llindar de decisió. Posteriorment, el conjunt de test s'utilitza per avaluar i comparar el rendiment de les diferents configuracions.

5.2 Preprocessament del text

Abans d'entrenar els models, s'ha dut a terme un procés de preprocessament dels textos amb l'objectiu de reduir el soroll i facilitar l'aprenentatge dels classificadors.

S'han eliminat elements típics de xarxes socials que no aporten informació rellevant per a la detecció de toxicitat. En concret, s'han eliminat mencions a usuaris (@user), enllaços (URLs) i indicadors de retweets (RT). També s'han eliminat alguns caràcters i símbols innecessaris i s'han normalitzat els espais en blanc.

A més, s'ha realitzat una neteja específica d'emojis mitjançant expressions regulars, eliminant diferents rangs de caràcters Unicode corresponents a emoticones, símbols i pictogrames. També s'ha

aplicat una normalització de hashtags, eliminant el símbol # però mantenint el contingut textual associat, ja que pot aportar informació semàntica rellevant. Finalment, s'han eliminat els valors buits, tant els que ja existien al dataset com els generats durant el procés de neteja.

Aquest procediment constitueix el preprocessament general aplicat al dataset principal i també s'ha aplicat als datasets Jigsaw i de sarcasme en anglès, per tal que els textos poguessin ser processats de manera coherent durant l'avaluació. En el cas de Jigsaw, a més, s'han eliminat elements propis de les pàgines de discussió de Wikipedia, com les adreces IP, les marques temporals i la indicació *UTC*. En canvi, en el dataset de sarcasme en castellà no va ser necessari aplicar una neteja específica, ja que els textos ja es trobaven en un format adequat.

5.3 Anàlisi exploratòria de dades del dataset principal

Un cop preprocessats els textos, s'ha realitzat una anàlisi exploratòria de dades (EDA) amb l'objectiu de comprendre millor les característiques del dataset.

En primer lloc, s'ha analitzat la distribució de les classes, observant un cert desbalanceig entre textos tòxics i no tòxics.

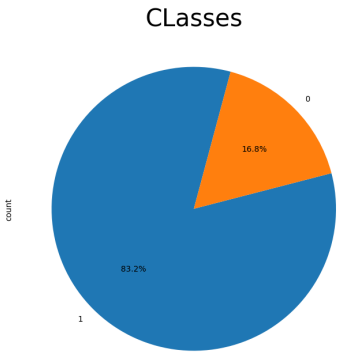
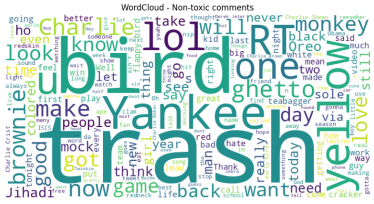


Figura 1: Distribució de les classes en el dataset

A continuació, s'han generat núvols de paraules (*wordclouds*) per a cada classe, amb l'objectiu d'identificar visualment els termes més freqüents associats als textos tòxics i no tòxics.



Textos tòxics



Textos no tòxics

Figura 2: Núvols de paraules per classe

Finalment, s'ha analitzat la distribució de les paraules més freqüents mitjançant gràfics de freqüència, comparant la seva presència entre classes.

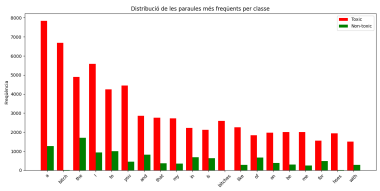


Figura 3: Distribució de les paraules més freqüents per classe

Aquests gràfics mostren que en els textos tòxics apareixen amb més freqüència termes clarament ofensius o insultants, com *bitch*, *fuck*, *hoe* o *ass*, mentre que en els textos no tòxics predominen paraules més generals i pròpies de converses quotidianes, com *today*, *know*, *time* o *people*. Tot i això, també s'observa que algunes paraules comunes apareixen en ambdues classes, fet que indica que la toxicitat no depèn només de paraules individuals, sinó també del context en què apareixen. Aquest aspecte s'analitzarà amb més detall posteriorment mitjançant l'estudi dels n-grams i dels errors de classificació del model.

5.4 Tokenització i representació del text

Un cop preprocessats els textos, es procedeix a la seva transformació en una representació numèrica que permeti aplicar models de machine learning. Aquest procés es basa en la tokenització del text i en la construcció de vectors de característiques.

En aquest treball, la tokenització es realitza de manera implícita mitjançant els vectoritzadors *CountVectorizer* i *TfidfVectorizer* de la llibreria *scikit-learn*. Aquests mètodes divideixen automàticament els textos en unitats bàsiques (tokens), que en aquest cas corresponen principalment a paraules.

A més, s'utilitzen n-grams de paraula amb un rang de (1,2), és a dir, es tenen en compte tant paraules individuals (unigrams) com seqüències de dues paraules consecutives (bigrams). Aquesta configuració permet capturar no només el significat individual de les paraules, sinó també relacions simples entre elles.

Pel que fa a la representació del text, s'han utilitzat dues tècniques principals:

- **Bag-of-Words (BoW):** representa cada text com un vector de freqüències de paraules, sense tenir en compte l'ordre. Aquesta representació és simple però efectiva per a textos curts.
- **TF-IDF:** pondera la importància de cada paraula en funció de la seva freqüència en el document i la seva freqüència inversa en el conjunt de dades. Això permet reduir el pes de paraules molt comunes i destacar aquelles més informatives.

Finalment, s'ha limitat el vocabulari mitjançant el paràmetre *min_df*, eliminant aquells termes que apareixen amb molt poca freqüència, amb l'objectiu de reduir el soroll i la dimensionalitat de l'espai de característiques.

Per evitar qualsevol fuga d'informació, els vectoritzadors utilitzats per construir les representacions Bag-of-Words i TF-IDF s'han ajustat (fit) exclusivament amb les dades d'entrenament de cada experiment. Posteriorment, aquests vectoritzadors s'han aplicat (transform) sobre els corresponents conjunts de test.

5.5 Models de classificació

En aquest treball s'han implementat diversos models clàssics de classificació de text, per tal de comparar el seu rendiment en la tasca de detecció de llenguatge tòxic. En concret, s'han utilitzat els següents models:

- Logistic Regression
- Support Vector Machines (Linear SVM)
- Multinomial Naive Bayes
- Complement Naive Bayes
- Bernoulli Naive Bayes

Aquests models s'han escollit per la seva simplicitat, eficiència computacional i interpretabilitat, especialment adequats per a tasques de classificació de textos curts. Per a cada model, s'han avaluat dues representacions del text: Bag-of-Words i TF-IDF. Això permet analitzar l'impacte de la representació del text en el rendiment dels classificadors, mantenint constant l'algoritme de classificació. A més, tots els models s'han entrenat i avaluat seguint la mateixa metodologia, per tal de garantir una comparació justa entre les diferents configuracions.

5.6 Cerca d'hiperparàmetres

Per tal d'optimitzar el rendiment dels models clàssics de classificació de text, s'ha realitzat una petita cerca d'hiperparàmetres mitjançant validació creuada sobre el conjunt d'entrenament del dataset principal. Aquesta estratègia permet obtenir una estimació robusta del rendiment evitant la dependència d'una única partició train/test.

Concretament, s'ha utilitzat una validació creuada de 5 particions (k-fold), on el conjunt de dades principal es divideix en 5 subconjunts. En cada iteració, un subconjunt s'utilitza com a validació i la resta com a entrenament, repetint el procés fins a cobrir totes les particions.

Els espais d'hiperparàmetres considerats són els següents:

- **Logistic Regression**: s'ha ajustat el paràmetre de regularització $C \in \{0.01, 0.1, 1, 10\}$.
- **Linear SVM**: s'ha optimitzat també el paràmetre $C \in \{0.01, 0.1, 1, 10\}$, que controla el compromís entre marge i error de classificació.
- **Multinomial Naive Bayes**: s'ha explorat el paràmetre de suavització $\alpha \in \{0.01, 0.1, 0.5, 1, 10\}$.
- **Complement Naive Bayes**: variant robusta davant desbalanceig, amb $\alpha \in \{0.01, 0.1, 0.5, 1\}$.
- **Bernoulli Naive Bayes**: orientat a dades binàries, amb $\alpha \in \{0.01, 0.1, 0.5, 1\}$.

Per a cada combinació d'hiperparàmetres, s'ha calculat el F1-macro mitjà sobre les diferents particions de la validació creuada, seleccionant finalment la configuració amb millor rendiment.

5.7 Avaluació del rendiment

El rendiment dels models s'ha avaluat utilitzant la mètrica F1-macro, especialment adequada en presència de dades desbalancejades. Per al model final, aquesta mètrica s'ha complementat amb l'anàlisi de les matrius de confusió, que permeten observar amb més detall els encerts i els errors de classificació en cada classe.

Els models s'han avaluat en dos escenaris: el conjunt de test del dataset principal (avaluació in-domain) i el dataset Jigsaw (avaluació out-of-domain) per analitzar la capacitat de generalització.

6 Resultats base

En aquesta secció es presenten els resultats obtinguts amb els diferents models de classificació utilitzant dues representacions del text: Bag-of-Words i TF-IDF. A més, es considera tant la configuració base com la versió amb ajust d'hiperparàmetres mitjançant validació creuada.

6.1 Resultats en el dataset principal

La Taula 1 mostra el rendiment dels diferents models en el conjunt de test del dataset principal.

Model	**BoW**	**TF-IDF**	**BoW (tuned)**	**TF-IDF (tuned)**
Logistic Regression	0.9222	0.8750	0.9222	0.9129
Linear SVM	0.9060	0.9150	**0.9263**	0.9150
Multinomial NB	0.8809	0.7426	0.8809	0.8205
Complement NB	0.8832	0.8742	0.8822	0.8742
Bernoulli NB	0.8755	0.8755	0.8884	0.8884

Taula 1: Resultats en el conjunt de test del dataset principal

Tal com es pot observar, el millor rendiment s'obté amb el model Linear SVM utilitzant la representació Bag-of-Words amb ajust d'hiperparàmetres ($C = 0.1$), assolint un F1-macro de 0.926. Aquest resultat és superior a la resta de configuracions, indicant que aquest model és el més adequat per al domini dels textos de Twitter.

D'altra banda, es pot observar que l'ús de TF-IDF no millora necessàriament el rendiment en aquest cas, i que l'impacte de l'ajust d'hiperparàmetres és limitat en la majoria de models, amb l'excepció del Linear SVM.

6.2 Resultats en el dataset Jigsaw

Per analitzar la capacitat de generalització dels models, s'han avaluat sobre el dataset Jigsaw, que presenta característiques diferents de les del dataset principal. Els resultats corresponen als models amb els hiperparàmetres seleccionats prèviament mitjançant validació creuada sobre el dataset principal.

Model	BoW (Jigsaw)	TF-IDF (Jigsaw)
Logistic Regression	0.6521	0.5000
Linear SVM	**0.6431**	0.5296
Multinomial NB	0.6110	0.3777
Complement NB	**0.6917**	0.5874
Bernoulli NB	0.6216	0.6216

Taula 2: Resultats en el dataset Jigsaw

En aquest cas, el comportament dels models és diferent. Complement NB amb Bag-of-Words obté el millor rendiment, superant el Linear SVM.

6.3 Anàlisi dels resultats

La diferència de rendiment entre el dataset principal i el dataset Jigsaw posa de manifest la presència d'un canvi de domini (*domain shift*). Mentre que el dataset principal està format per textos curts i informals (tweets), el dataset Jigsaw conté comentaris més llargs, estructurats i amb més context.

Aquesta diferència afecta tant la distribució de les paraules com la manera en què es manifesta la toxicitat, fet que explica per què un model òptim en un domini no necessàriament ho és en un altre.

Tot i que alguns models obtenen millors resultats en el dataset Jigsaw, en aquest treball es decideix centrar l'anàlisi en el model **Linear SVM** amb representació **Bag-of-Words**, ja que és el que ofereix millor rendiment en el conjunt de test del dataset principal (amb la cerca d'hiperparàmetres), que constitueix l'escenari principal del problema.

6.3.1 Anàlisi de la definició de toxicitat

A més d'aquest canvi de domini, s'ha analitzat també l'impacte de la definició de les etiquetes en el dataset Jigsaw. En concret, s'ha comparat la binarització inicial, basada en les etiquetes *toxic* o *severe_toxic*, amb una definició més àmplia que considera com a tòxic qualsevol comentari amb alguna de les etiquetes disponibles (*toxic, severe_toxic, obscene, insult, threat, identity_hate*).

Per a aquesta anàlisi s'utilitza el model Linear SVM, seleccionat prèviament com a model de referència, considerant tant la representació Bag-of-Words com TF-IDF per estudiar l'efecte del canvi en la definició de toxicitat.

Representació	Binarització	F1-macro
BoW	toxic OR severe_toxic	0.6431
BoW	OR totes les etiquetes	0.6501
TF-IDF	toxic OR severe_toxic	0.5296
TF-IDF	OR totes les etiquetes	0.5370

Taula 3: Impacte de la definició de toxicitat en el dataset Jigsaw

Els resultats mostren que ampliar la definició de toxicitat produeix una lleugera millora del rendiment en ambdues representacions. Aquest increment indica que el model és capaç de detectar

formes de llenguatge ofensiu (com insults o obscenitats) que no estaven incloses en la definició inicial basada únicament en *toxic* i *severe_toxic*.

Això suggereix que part de la pèrdua de rendiment observada en el dataset Jigsaw no es deu únicament a diferències en el llenguatge entre datasets (*domain shift*), sinó també a diferències en els criteris d'etiquetatge i en la definició de la variable objectiu. En altres paraules, el model pot estar capturant patrons ofensius que no sempre coincideixen amb la manera com la toxicitat ha estat definida i anotada en aquest dataset.

Igualment, es considera més adequat mantenir una definició estricta de toxicitat, assegurant que els casos classificats com a positius corresponen efectivament a contingut clarament tòxic, tot i que això impliqui una lleugera reducció del rendiment en aquest dataset.

7 Millores i experiments

A partir d'aquest punt, les millores es realitzen sobre el **model base (Linear SVM amb Bag-of-Words)**, amb l'objectiu d'analitzar l'impacte de diferents tècniques tant en el dataset principal com en el dataset Jigsaw. D'aquesta manera, es pot estudiar si les modificacions milloren el rendiment en l'escenari *in-domain* i, alhora, la capacitat de generalització en l'escenari *out-of-domain*.

7.1 Pesos de classe

S'ha analitzat l'ús de pesos de classe per compensar el desequilibri entre les classes del dataset. No obstant això, aquesta tècnica ha donat lloc a valors d'F1-macro molt similars en els dos datasets, sense aportar una millora clara. Per aquest motiu, s'ha decidit mantenir la configuració original del model sense ponderació de classes.

7.2 Ajust del llindar de decisió

S'ha estudiat l'impacte de modificar el llindar de decisió del model Linear SVM, amb l'objectiu d'optimitzar la mètrica F1-macro. Per fer-ho, s'ha realitzat una cerca sobre diferents valors del llindar (s'han avaluat 50 valors equiespaiats en l'interval $[-2, 2]$) utilitzant validació creuada sobre el conjunt d'entrenament. El valor òptim obtingut va ser $t = 0.1224$.

En el cas del model Linear SVM, el llindar s'aplica sobre els valors de la funció de decisió (*decision_function*), que representen el marge de separació entre classes.

Configuració	**F1 Dataset Principal**	**F1 Jigsaw**
WORD (baseline)	0.9263	0.6431
WORD + threshold	0.9269	0.6789

Taula 4: Impacte de l'ajust del llindar de decisió

Tal com es pot observar, la millora en el conjunt de test és mínima, passant de 0.9263 a 0.9269. No obstant això, en el dataset Jigsaw s'observa una millora més notable. Això indica que l'ajust del llindar té un impacte limitat en el domini original, però pot ajudar a millorar la generalització.

7.3 N-grams de caràcter

S'han incorporat n-grams de caràcter de longitud entre 3 i 5, amb l'objectiu de capturar patrons sublèxics, variacions ortogràfiques, errors tipogràfics i possibles deformacions de paraules ofensives.

Configuració	**F1 Dataset Principal**	**F1 Jigsaw**
WORD (baseline)	0.9263	0.6431
CHAR	0.9149	0.6698

Taula 5: Impacte dels n-grams de caràcter

Els resultats mostren que aquesta representació redueix el rendiment en el conjunt de test del dataset principal, però millora el rendiment en el dataset Jigsaw.

7.4 Combinació de millores

S'ha analitzat la combinació de n-grams de paraula i caràcter juntament amb l'ajust del llindar de decisió. Tot i que aquesta configuració modifica l'espai de característiques del model, el procés d'optimització del llindar mitjançant validació creuada va tornar a seleccionar el mateix valor que en el model WORD original, obtenint-se novament $t = 0.1224$.

Configuració	**F1 Dataset Principal**	**F1 Jigsaw**
WORD	0.9263	0.6431
WORD + CHAR	0.9168	0.6722
WORD + CHAR + threshold	0.9222	0.6913

Taula 6: Combinació de millores

La combinació de tècniques permet millorar la generalització, assolint el millor resultat en el dataset Jigsaw amb la configuració WORD + CHAR + threshold, mantenint alhora un rendiment competitiu en el conjunt de test del dataset principal.

7.5 Eliminació de stopwords

S'ha analitzat l'impacte de l'eliminació de les stopwords en el rendiment del model. Les stopwords són paraules molt freqüents (com ara articles, preposicions o pronoms) que sovint s'eliminen en tasques de processament de llenguatge natural per reduir soroll. No obstant això, en el context de la detecció de toxicitat, aquestes paraules poden aportar informació rellevant sobre l'estructura i el context del missatge.

En aquesta configuració, l'eliminació de stopwords modifica l'espai de característiques del model WORD+CHAR. Per aquest motiu, es recalcula el llindar de decisió òptim mitjançant validació creuada, obtenint-se un valor de $t = 0.2041$, diferent del llindar utilitzat en les configuracions anteriors.

Configuració	F1 Dataset Principal	F1 Jigsaw
Model final original	0.9222	0.6913
Sense stopwords	0.9172	0.7242

Taula 7: Resultats de l'eliminació de stopwords

Tal com es pot observar, l'eliminació de stopwords produeix una lleugera disminució del rendiment en el conjunt de test del dataset principal, mentre que en el dataset Jigsaw sí que s'observa una millora.

Tot i que l'eliminació de stopwords millora el rendiment en el dataset Jigsaw, es decideix mantenir-les. Aquesta decisió no es basa únicament en les mètriques obtingudes, sinó també en un criteri lingüístic, ja que les paraules funcionals poden aportar informació contextual rellevant, especialment en casos complexos com el sarcasme.

7.6 Adaptació de domini amb Jigsaw (experiment controlat)

Per analitzar la capacitat d'adaptació dels models a un nou domini, s'ha dut a terme un experiment en què s'ha incorporat una petita fracció del dataset Jigsaw al conjunt d'entrenament. Aquest escenari correspon a una adaptació supervisada al nou domini, ja que tant el model com el vectoritzador s'ajusten utilitzant dades de Jigsaw.

Per tal d'evitar problemes de *data leakage* i simular un escenari més realista, el dataset Jigsaw s'ha dividit en dues parts: un conjunt d'adaptació (Jigsaw-dev), corresponent al 10% de les dades, i un conjunt de test (Jigsaw-test), corresponent al 90% restant. Els models s'han entrenat utilitzant el dataset principal juntament amb Jigsaw-dev, i l'avaluació final s'ha realitzat exclusivament sobre Jigsaw-test. Per evitar qualsevol fuga d'informació, el vocabulari s'ha construït únicament a partir de les dades d'entrenament combinades (*train* + Jigsaw-dev), sense utilitzar informació de Jigsaw-test.

L'experiment s'ha realitzat sobre dues configuracions amb ajust del llindar de decisió: el model basat en n-grams de paraula (WORD + threshold) i el model final, que combina n-grams de paraula i de caràcter (WORD + CHAR + threshold).

Configuració	F1 Dataset Principal	F1 Jigsaw
WORD + threshold	0.9269	0.6789
WORD + CHAR + threshold	0.9222	0.6913
WORD + threshold + adaptació 10%	0.9314	0.8346
WORD + CHAR + threshold + adaptació 10%	0.9253	0.8367

Taula 8: Resultats de l'adaptació de domini amb un 10% de dades de Jigsaw

Cal tenir en compte que els resultats sense adaptació s'han calculat sobre el conjunt complet de Jigsaw, mentre que les configuracions amb adaptació s'han avaluat sobre el subconjunt Jigsaw-test, corresponent al 90% de les dades. Per tant, la comparació s'ha d'interpretar com a orientativa, ja que els resultats no s'han obtingut exactament sobre els mateixos exemples.

Els resultats mostren que la incorporació d'un 10% de dades del nou domini produeix una millora molt notable en el rendiment sobre Jigsaw en ambdues configuracions. En el cas del model basat en n-grams de paraula amb ajust del llindar, l'F1-macro augmenta de 0.6789 a 0.8346, mentre que en el model final passa de 0.6913 a 0.8367.

Al mateix temps, el rendiment en el conjunt de test del dataset principal es manté estable, amb variacions molt petites entre configuracions. Això indica que la incorporació de dades del nou domini no perjudica de manera rellevant el comportament dels models en el domini original.

Cal destacar que els resultats obtinguts amb les dues configuracions després de l'adaptació són molt similars. Aquest fet suggereix que la millora principal prové de la incorporació de dades del nou domini, més que de la complexitat del model utilitzat.

Aquests resultats evidencien que una petita quantitat de dades etiquetades del nou domini és suficient per reduir de manera notable el *domain shift*, millorant la capacitat de generalització del model.

Tot això es planteja com una anàlisi independent i no s'utilitza per definir el model final del treball. L'objectiu és únicament estudiar l'impacte de la incorporació de dades del nou domini en la capacitat de generalització dels models.

7.7 Model final seleccionat

Els experiments realitzats mostren que els models lineals basats en representacions n-gram obtenen un rendiment molt elevat en el domini original dels tweets. No obstant això, aquest rendiment disminueix quan els models s'avaluen en un domini diferent, evidenciant tant l'efecte del *domain shift* com les diferències en els criteris d'etiquetatge i en la definició de la variable objectiu.

Els resultats també indiquen que certes estratègies, com l'ajust del llindar de decisió i la incorporació de n-grams de caràcter, permeten reduir parcialment aquesta pèrdua de generalització. A més, la incorporació d'una petita quantitat de dades del nou domini produeix una millora molt significativa del rendiment out-of-domain.

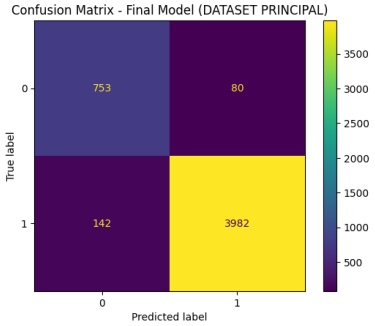
A partir d'aquests resultats, es selecciona com a **model final** la configuració que combina n-grams de paraula i caràcter juntament amb l'ajust del llindar de decisió. Tot i que aquesta configuració redueix lleugerament el rendiment en el conjunt de test del dataset principal (de 0.926 a 0.922 en F1-macro), presenta una millora més significativa en el dataset Jigsaw, passant de 0.643 a 0.691.

La selecció del model final es planteja com una decisió multicriteri, on es prioritza la robustesa out-of-domain mantenint al mateix temps un rendiment elevat en l'escenari in-domain. En aquest treball, no es considera únicament el millor resultat en el dataset principal, sinó també la capacitat del model per generalitzar a textos amb característiques diferents.

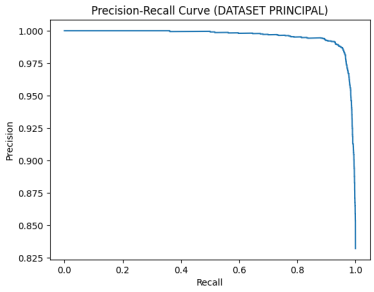
En concret, s'assumeix que, en una aplicació real, el domini dels textos pot variar respecte al conjunt d'entrenament. Per aquest motiu, es prioritza una configuració que optimitzi el compromís entre el rendiment in-domain i el rendiment out-of-domain, fins i tot si això implica una lleugera reducció de l'F1-macro en el dataset original.

7.7.1 Anàlisi en el dataset principal

El model final obté un F1-macro de 0.922 en el conjunt de test del dataset principal.



Matriu de confusió



Corba Precision-Recall

Figura 4: Resultats del model final en el dataset principal

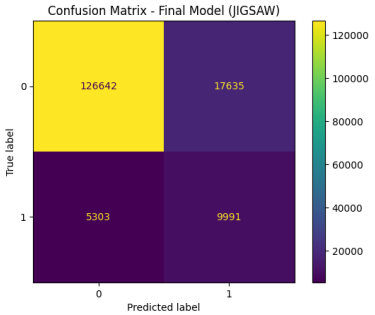
Classe	Precision	Recall
No tòxic (0)	0.84	0.90
Tòxic (1)	0.98	0.97

Taula 9: Mètriques per classe en el dataset principal

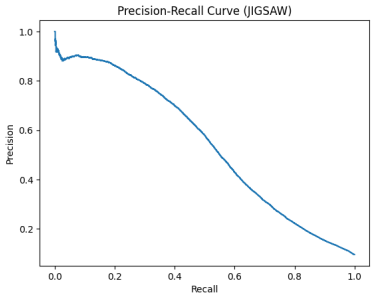
El model presenta un rendiment elevat en aquest domini, especialment en la detecció de la classe tòxica, amb valors alts de *precision* i *recall*. La corba *precision-recall* mostra que el model manté una precisió elevada per a un ampli rang de *recall*, fet que evidencia un bon compromís entre la detecció de comentaris tòxics i la reducció de falsos positius.

7.7.2 Anàlisi en el dataset Jigsaw

En el dataset Jigsaw, el model obté un F1-macro de 0.691.



Matriu de confusió



Corba Precision-Recall

Figura 5: Resultats del model final en el dataset Jigsaw

Classe	Precision	Recall
No tòxic (0)	0.96	0.88
Tòxic (1)	0.36	0.65

Taula 10: Mètriques per classe en el dataset Jigsaw

En aquest cas, el model mostra una degradació significativa del rendiment. La baixa precisió en la classe tòxica indica un nombre elevat de falsos positius, mentre que el recall moderat reflecteix una capacitat parcial de detecció. La corba precision-recall mostra una caiguda progressiva de la precisió a mesura que augmenta el recall, evidenciant la dificultat del model per mantenir un bon equilibri en aquest domini.

Aquest comportament es pot explicar pel fenomen de *domain shift*, així com per les diferències en els criteris d'etiquetatge i en la definició de toxicitat analitzades prèviament.

La degradació del rendiment en el dataset Jigsaw es manifesta principalment en una disminució important de la precisió de la classe tòxica, indicant un nombre elevat de falsos positius. En un escenari real de moderació automàtica, aquest comportament es traduiria en *overblocking*, és a dir, en el bloqueig o marcat incorrecte de comentaris legítims com a tòxics. Tal com es veurà en l'anàlisi qualitativa posterior, aquest fenomen està relacionat amb la tendència del model a interpretar desacords, queixes o textos argumentatius com a toxicitat.

8 Anàlisi qualitativa

8.1 Interpretabilitat del model basada en n-grams

Tot i que els núvols de paraules permeten obtenir una primera visió general del contingut dels textos, aquests no són suficients per justificar el comportament del model de classificació. Per aquest motiu, es realitza una anàlisi més rigorosa basada en els coeficients del model lineal.

En models com el Linear SVM, cada n-gram té associat un coeficient que indica la seva contribució a la classificació. Els coeficients positius estan associats a la classe tòxica, mentre que els coeficients negatius indiquen associació amb la classe no tòxica. Això permet interpretar quines paraules o expressions són més rellevants per a la presa de decisions del model. Per facilitar la interpretació, l'anàlisi següent se centra en el component de n-grams de paraula del model final. Per tant, les contribucions mostrades ofereixen una explicació parcial de les prediccions, ja que el model també incorpora n-grams de caràcter.

També cal tenir en compte que aquesta interpretabilitat és principalment local i lèxica, ja que el model no captura adequadament informació pragmàtica, dependències contextuals llargues o significats no literals.

A continuació es mostren els n-grams de paraula amb major pes positiu i negatiu.

Tòxic	Coef
fag	0.4561
hoe	0.3406
ass	0.2679
hoes	0.2501
shit	0.2469
bitch	0.2159
cunt	0.2122
fuck	0.1919
trash though	0.1871
nig	0.1862
white trash	0.1666
negro	0.1630
pussy	0.1610
wtf	0.1496
fags	0.1489
he trash	0.1414
coons	0.1389
dyke	0.1379
re trash	0.1374
stfu	0.1310

No tòxic	Coef
hoe hoe	-0.2396
night	-0.1508
hmu	-0.1342
trash	-0.1213
hi ho	-0.1112
via	-0.1073
hoe rt	-0.1059
shy	-0.1052
rt why	-0.1028
my nips	-0.1018
slap hoe	-0.0978
slap	-0.0954
el	-0.0932
the trash	-0.0912
crackers	-0.0911
like it	-0.0908
hoes and	-0.0892
is that	-0.0864
charlie	-0.0860
negros	-0.0850

Taula 11: N-grams amb major pes positiu (tòxics) i negatiu (no tòxics)

N-grams associats a la classe tòxica

- **Predomini d'insults explícits:** Els n-grams amb major pes positiu corresponen gairebé exclusivament a insults o termes despectius (*fag*, *bitch*, *cunt*, *fuck*, *dyke*, *coons*), cosa que mostra que el model identifica la toxicitat principalment a través de vocabulari ofensiu explícit.
- **Importància del context mitjançant bigrams:** Alguns dels n-grams més rellevants són combinacions de paraules com *white trash*, *trash though* o *he trash*, que indiquen que el model no només detecta insults individuals, sinó també petits patrons contextuals ofensius.
- **Predomini de vocabulari clarament discriminatori:** Els termes amb pes positiu mostren una coherència semàntica notable, ja que la majoria corresponen a insults o expressions despectives. Això reforça que la classe tòxica està definida per patrons lèxics bastant específics.

N-grams associats a la classe no tòxica

- **Predomini de paraules neutres i llenguatge informal:** Els coeficients negatius no segueixen un patró semàntic tan clar i inclouen paraules neutres o freqüents en conversa informal, com *night*, *via*, *like it* o *is that*. Això suggereix que la classe no tòxica es defineix més per absència de toxicitat que per un vocabulari específic.
- **Ambigüitat lèxica i dependència del context:** Alguns termes potencialment ofensius poden aparèixer també en contextos no tòxics, fet que mostra que el model capta parcialment usos contextuals diferents. Per exemple, *trash* apareix tant en *white trash* (tòxic) com en *the*

trash (no tòxic). De manera similar, *hoe* rep pes positiu quan s'interpreta com a insult, però apareix amb pes negatiu en expressions com *hoe hoe* o en el seu sentit literal d'eina agrícola. També casos com *negro/negros* o *crackers* suggereixen que petites variacions lèxiques i el context poden alterar la classificació.

8.2 Anàlisi d'errors

Per entendre millor les limitacions del model, es realitza una anàlisi qualitativa dels errors observats tant en el dataset principal com en el dataset Jigsaw.

Els resultats mostren que gran part dels errors poden explicar-se per tres factors principals: la dependència de patrons lèxics i paraules amb múltiples significats, les limitacions de cobertura de vocabulari entre dominis i les diferències estructurals entre textos curts i textos més llargs i discursius.

8.2.1 Artefactes del dataset i polisèmia

Una part important dels errors observats està relacionada amb la dependència de patrons lèxics locals i amb la presència de paraules amb múltiples significats. En aquests casos, el model tendeix a associar determinats termes amb toxicitat independentment del context concret en què apareixen.

Aquest comportament és conseqüència directa de l'ús de representacions basades en n-grams, on certes paraules adquireixen pesos molt elevats durant l'entrenament, fent que paraules potencialment ofensives puguin dominar la classificació encara que apareguin en usos completament neutres.

Dataset principal

Exemple 1 (FP): "Remember Dad running a rotary hoe over corn after a freeze to knock the dead leaves off after they turn brown"

El terme *hoe* domina la classificació tot i aparèixer en un context completament neutre relacionat amb agricultura.

Exemple 2 (FP): "Ho ho ho."

La repetició del patró *ho* incrementa la contribució tòxica. Està interpretant la paraula com un insult (*hoe*), però en aquest cas correspon a una expressió associada al riure o a l'expressió típica de Santa Claus, sense cap significat ofensiu.

Exemple 3 (FN): "im weeaboo trash"

Tot i contenir el terme *trash*, aquest presenta un pes negatiu en el model i contribueix incorrectament a una classificació no tòxica.

Exemple 4 (FP): "You realize I'm going to have to get out all those horror and other poems I wrote abo..."

Tot i no contenir insults explícits, el model assigna contribucions positives a patrons freqüents com *you* o *you realize*, provocant una classificació incorrecta.

Exemple 5 (FN): "a girl tweeted "you might be ghetto if u bring food from outside into the movies"no u might be stupid if u pay 4.99"

Expressions com *you might be* o *ghetto if* tenen pesos baixos o negatius, fet que dilueix la toxicitat del missatge.

Exemple 6 (FP): "But rich is a light skin coon. So it's expected."

El terme *coon* domina la classificació i és suficient per etiquetar el text com a tòxic independentment del context global. Cal destacar, però, que en aquest cas el model podria estar encertant, ja que coon és un insult racial explícit. Si el text està etiquetat com a no tòxic al dataset original, podria tractar-se d'un error d'etiquetatge humà més que d'un error del model.

Aquests exemples mostren que el model depèn principalment de correlacions lèxiques locals i no disposa de mecanismes per distingir significats segons el context.

8.2.2 Cobertura de vocabulari i problemes out-of-vocabulary

Una altra font important d'errors prové de les diferències de vocabulari entre datasets. Els models basats en n-grams de paraula depenen fortament dels termes observats durant l'entrenament, fet que dificulta la detecció d'insults rars, variants ortogràfiques o expressions poc freqüents.

Aquest problema es fa especialment visible en escenaris *out-of-domain*, on apareixen insults o construccions lingüístiques diferents de les presents al dataset principal. A més, els textos en altres idiomes o amb vocabulari específic del nou domini dificulten encara més la capacitat de generalització del model.

Dataset principal

Exemple 7 (FN): "Bij vraag wat is d naam van de engels des doods,dacht eerst Robert.Ik:Israel..uhm iets met Gargamel,hoe heet die kat ook al weer..oja Azrael"

El text està majoritàriament en un altre idioma, impedint que el model identifiqui patrons de toxicitat.

Exemple 8 (FN): "Ja zo denkt ieder wel 't zijne over zaken he. je mag mij noemen hoe je wilt, ben namelijk erg voor vrijheid van meningsuiting."

De nou, el model no detecta correctament la toxicitat degut a la presència d'un idioma diferent del conjunt d'entrenament.

Dataset Jigsaw

Exemple 9 (FN): "THE GUY ABOVE ME IS A WANKER!!"

Tot i ser un insult directe, el terme *wanker* no apareix amb freqüència en el dataset d'entrenament i el model no el detecta com un insult.

Aquests casos evidencien la dependència del model respecte al vocabulari observat durant l'entrenament. Aquest comportament ajuda també a explicar per què els n-grams de caràcter milloren el rendiment *out-of-domain*, ja que permeten capturar patrons sublèxics i similituds parcials entre paraules no observades.

8.2.3 Efecte de la longitud i de l'estil discursiu

El dataset Jigsaw presenta textos considerablement més llargs i amb un estil més formal i argumentatiu que el dataset principal. Aquest canvi estructural afecta de manera important el comportament del model i constitueix una de les principals manifestacions del *domain shift* observat durant els experiments.

En els textos més llargs, les contribucions de paraules ofensives poden quedar diluïdes entre un gran nombre de termes neutres. Al mateix temps, el model tendeix a interpretar desacords, queixes o discussions formals com a toxicitat, ja que moltes d'aquestes estructures comparteixen vocabulari amb contextos conflictius presents al conjunt d'entrenament.

Dataset Jigsaw

Exemple 10 (FP): "No, you're incorrect. Kww and I is the correct way."

El model interpreta incorrectament un desacord neutre com a toxicitat.

Exemple 11 (FP): "Argh, I just discovered that you copied Trans-Mississippi Exposition from even though they have big copyright notices all over the site. That is a big no-no - I'm going to have to delete the copied material. 06:08, 17 Jul 2004"

Un text argumentatiu i formal és classificat com a tòxic a causa de l'acumulació de termes associats a contextos conflictius.

Exemple 12 (FP): "I just want to resolve this issue. Can you stop blocking me with robots (just look at my talk page). This is original content, in breach of the copyright law. Give me a phone number or an email address, or at least an on-line way to find someone who can deal with this."

Un missatge de queixa formal és classificat com a tòxic a causa de la presència de termes freqüents en contextos conflictius.

Exemple 13 (FP): "I believe that you have erred in the interpretation of wikipedia policy and rights, I am contacting authorities for your non-consented use of my signature in your discussion page."

El llenguatge crític i argumentatiu es confon amb toxicitat.

Exemple 14 (FN): "RE: "and he picked his nose too!!"What are you, some kind of Klansman? Taney was a racist douchebag and he's probably burning in Hell. Any and all negative aspersions towards him should be in bold print, along with Photoshopped pictures of him engaging in fellatio with a Rottweiler."

Tot i contenir múltiples insults, la longitud del text i la dispersió dels termes ofensius dificulten la detecció.

Exemple 15 (FN): "Are you really going to let that guy walk away scout free, because he's an admin, and block me because I was concerned about a conflict of interest? I want to take this up with ARBCOM. This is ridiculous."

El to discursiu i argumentatiu dilueix les contribucions tòxiques del missatge.

Exemple 16 (FN): "UD is now about Homewrecking Sluts Karen Nussle did accept money from

that prostitutional family. I'm a TULIP boy. UD is now on the Dark Side. I would like to save UD"

Tot i contenir insults explícits (*sluts*), aquests tenen una contribució insuficient dins del conjunt del text.

Aquests resultats mostren que el *domain shift* no afecta únicament el vocabulari, sinó també l'estructura discursiva dels textos.

9 Sarcasme com a conjunt de prova d'estrès

Per analitzar el comportament del model davant de fenòmens lingüístics complexos, s'ha utilitzat el dataset de sarcasme en anglès com a conjunt de prova d'estrès. Aquest conjunt no s'ha utilitzat durant l'entrenament, sinó únicament per avaluar la robustesa del model en un escenari fora del domini original.

En aquest experiment es parteix de la hipòtesi que el sarcasme pot constituir un fenomen especialment problemàtic per a classificadors basats en n-grams, ja que aquests models tendeixen a dependre fortament de patrons lèxics superficials i poden no captar adequadament usos irònics o no literals del llenguatge. En particular, s'espera que els textos sarcàstics presentin una taxa de prediccions tòxiques més elevada que els textos no sarcàstics, fins i tot en absència d'etiquetes explícites de toxicitat.

Atès que el dataset no inclou etiquetes de toxicitat, no és possible mesurar falsos positius ni falsos negatius. En lloc d'això, s'analitza la propensió del model a activar la classe tòxica (toxic prediction rate) com a indicador de robustesa fora de domini. Aquesta mètrica es calcula separadament per als textos sarcàstics i per als textos no sarcàstics.

Els resultats obtinguts són els següents:

- Textos sarcàstics: 0.1972
- Textos no sarcàstics: 0.1665

Aquests resultats mostren que la proporció de textos classificats com a tòxics és superior en el grup sarcàstic. Tot i que la diferència és moderada, suggereix que el sarcasme pot actuar com un factor que dificulta la classificació en alguns casos. No obstant això, aquesta prova no permet atribuir causalment aquesta diferència exclusivament al sarcasme, ja que els dos grups també poden diferir en vocabulari, temàtica i estil discursiu.

Per entendre millor aquest comportament, s'ha dut a terme una anàlisi qualitativa dels textos sarcàstics classificats com a tòxics. L'anàlisi dels exemples permet distingir dos patrons principals de comportament del model davant del sarcasme.

- **Sarcasme amb lèxic ofensiu explícit**

  En aquest primer grup, els textos contenen insults o expressions clarament associades amb toxicitat. En aquests casos, és esperable que el model classifiqui els missatges com a tòxics, ja que la presència de termes ofensius actua com un senyal lèxic molt fort.

  – "Fuck you too!"

  - "Do i look like i give a shit granny?"
  - "Shit I had *excellent* credit when I was an 18 year old dumb ass, Gunny."
  - "Yeah because literally every single person who thinks Trump is the right man for the job over Hillary is retarded, right?"

  La presència de termes com *fuck*, *shit*, *dumb ass* o *retarded* domina la classificació independentment de la intenció sarcàstica del missatge.

- **Sarcasme sense insults explícits**

  En el segon grup, els textos no contenen insults directes ni lèxic clarament ofensiu. La interpretació depèn principalment del to, de la ironia, de la hipèrbole o del context implícit del missatge.

  - "White Nail being added to QBB: Confirmed."
  - "Alright that's it, I'm changing my name so I don't have the same one as him"
  - "That's about the percentage of all white men in America still voting."
  - "I'm sure it was a white guy"
  - "Same place they got the gopro cameras... America"

  En aquests casos, el model no és capaç de distingir adequadament que el missatge correspon a un ús sarcàstic o irònic del llenguatge i acaba classificant-lo com a tòxic tot i no contenir insults explícits ni presentar indicis clars d'ofensivitat. Això suggereix que els models basats en n-grams tenen dificultats per interpretar significats no literals i depenen principalment de correlacions lèxiques superficials.

Aquesta comparació mostra que el sarcasme pot afectar el model de dues maneres diferents. En el primer grup, les prediccions són coherents amb una dependència excessiva de paraules ofensives amb pesos elevats. En el segon grup, en canvi, el problema principal sembla relacionat amb la dificultat dels models basats en n-grams per captar senyals pragmàtics, contextuals o no literals.

En conjunt, aquests resultats indiquen que el sarcasme constitueix un fenomen especialment desafiant per al model, incrementant la propensió del model a activar prediccions tòxiques. Aquesta limitació és coherent amb l'ús de representacions basades en n-grams, que capturen principalment regularitats lèxiques superficials però no interpreten adequadament la intenció comunicativa o el context global del missatge.

9.1 Comparació amb exemples no sarcàstics classificats com a tòxics

Per contextualitzar les prediccions observades en el conjunt sarcàstic, també s'ha analitzat una mostra de textos no sarcàstics classificats com a tòxics pel model. Alguns exemples representatius són:

- "At least I can read fuckface"
- "(((triggered)))"
- "Visa-free travel is also an important step forward, as Ukrainians will finally feel like normal people, because treatment of visa applicants at some embassies was shit."

- "Holy shit."
- "***YOU'RE A FUCKING WHITE MALE***"
- "Don't defend yourself against that bullshit."
- "Fucking brilliant!"
- "It is when they append said blood donation list with bigoted shit."

A diferència dels casos sarcàstics analitzats anteriorment, en aquest conjunt moltes de les prediccions del model semblen raonables, ja que diversos exemples contenen insults explícits, llenguatge ofensiu o un to clarament agressiu. En aquests casos, la classificació com a tòxic no sembla necessàriament un error, sinó una decisió coherent amb el contingut del text.

Això resulta rellevant perquè suggereix que, en els textos no sarcàstics, moltes de les prediccions tòxiques són plausibles, ja que els missatges contenen lèxic ofensiu explícit o un to clarament agressiu. En canvi, en els exemples sarcàstics, la classificació com a tòxics sembla estar més relacionada amb la dificultat del model per distingir quan determinades expressions s'utilitzen de manera irònica o no literal.

Aquesta comparació reforça la hipòtesi que el sarcasme introdueix una font específica de confusió per al model. Mentre que en els textos no sarcàstics les prediccions tòxiques sovint són justificables, en els textos sarcàstics apareixen més casos on el model sembla confondre ironia o humor amb toxicitat real.

9.2 Prova d'estrès addicional: sarcasme en castellà

Per complementar l'anàlisi anterior, s'ha realitzat un segon experiment utilitzant el dataset de sarcasme en castellà. Aquest escenari constitueix una prova d'estrès addicional, ja que el model s'aplica no només a textos sarcàstics, sinó també a una llengua diferent de la utilitzada durant l'entrenament.

De manera similar a l'experiment anterior, s'ha calculat el *toxic prediction rate*, és a dir, el percentatge de textos classificats com a tòxics pel model.

- Textos sarcàstics: 0.2111
- Textos no sarcàstics: 0.1254

Els resultats mostren que els textos sarcàstics en castellà presenten una taxa de prediccions tòxiques superior als textos no sarcàstics, reproduint el mateix patró observat en el dataset anglès.

Alguns exemples de sarcasmes classificats com a tòxics són:

- "¿Practicar un lunes? ¡Justo lo que yo quería hacer!"
- "Hay que ver, qué generoso"
- "Vagamente. Pero si lo que quieres es venganza, ¿por qué no me matas?"
- "Sí, no queremos que los niños se lastimen jugando al futbol. Pero creo que tengo un modo de mejorarlo más. ¿Por qué los jugadores no usan sostenes?"

En aquests casos, la classificació sembla relacionada amb l'ús d'hipèrboles, ironia o to implícit, més que amb la presència d'insults explícits.

Tot i això, aquests resultats no mesuren toxicitat real, sinó la propensió del model a activar prediccions tòxiques en un escenari simultani de canvi de llengua i llenguatge no literal. El fet que l'efecte sigui fins i tot més marcat que en el dataset anglès és coherent amb l'acumulació de dues fonts de desajust: la pragmàtica del sarcasme i el canvi lingüístic respecte al domini d'entrenament.

Cal destacar que l'objectiu d'aquest experiment no és analitzar en profunditat l'impacte del canvi de llengua ni avaluar la capacitat multilingüe del model, ja que aquest ha estat entrenat exclusivament amb textos en anglès. Aquest experiment es planteja únicament com una prova d'estrès complementària per observar el comportament del model davant la combinació de sarcasme i canvi lingüístic.

10 Conclusions

En aquest treball s'ha estudiat el problema de la detecció automàtica de llenguatge tòxic en textos curts mitjançant models clàssics de machine learning basats en representacions n-gram. En primer lloc, s'han implementat i comparat diversos classificadors, incloent Logistic Regression, Linear SVM, Multinomial Naive Bayes, Complement Naive Bayes i Bernoulli Naive Bayes, utilitzant representacions Bag-of-Words i TF-IDF. Els resultats mostren que el millor model baseline en el domini original és un Linear SVM amb representació Bag-of-Words i ajust d'hiperparàmetres, assolint un F1-macro de 0.9263 en el conjunt de test del dataset principal. Aquest resultat confirma que els models lineals basats en n-grams continuen sent molt competitius per a tasques de classificació de textos curts en dominis similars al conjunt d'entrenament.

L'avaluació sobre el dataset Jigsaw ha permès analitzar la capacitat de generalització dels models en un domini diferent. Els resultats mostren una disminució significativa del rendiment quan el model s'aplica a comentaris més llargs, formals i discursius, passant d'un F1-macro de 0.9263 en el dataset principal a 0.6431 en Jigsaw i evidenciant clarament el fenomen de *domain shift*. A més, l'anàlisi de diferents definicions de toxicitat en Jigsaw mostra que part d'aquesta pèrdua de rendiment no prové únicament de diferències lingüístiques entre dominis, sinó també de diferències en els criteris d'etiquetatge i en la definició de toxicitat. En concret, ampliar la definició de toxicitat a totes les etiquetes ofensives produeix una lleugera millora del rendiment, suggerint que el model és capaç de detectar formes de llenguatge ofensiu que no coincideixen exactament amb la definició inicial utilitzada en aquest dataset.

També s'han aplicat diverses estratègies amb l'objectiu de millorar els resultats. Els experiments mostren que l'ajust del llindar de decisió permet incrementar el rendiment sobre Jigsaw amb un impacte mínim en el domini original. De manera similar, la incorporació de n-grams de caràcter redueix lleugerament el rendiment in-domain però millora la detecció en el dataset Jigsaw. La combinació de n-grams de paraula, n-grams de caràcter i ajust del llindar proporciona el millor compromís entre rendiment *in-domain* i capacitat de generalització. També s'ha analitzat l'eliminació de stopwords, que produeix una petita millora addicional en el rendiment *out-of-domain*, tot i que finalment es decideix mantenir-les, ja que poden aportar informació contextual rellevant en casos complexos com el sarcasme.

A més, s'ha realitzat un experiment controlat d'adaptació de domini incorporant un 10% de dades etiquetades del dataset Jigsaw al conjunt d'entrenament. Els resultats mostren una millora molt significativa del rendiment *out-of-domain* en ambdues configuracions, passant aproximadament d'un F1-macro de 0.64–0.69 a valors superiors a 0.83, mantenint al mateix temps un rendiment estable en el dataset principal. Aquest resultat evidencia que una petita quantitat de dades etiquetades del nou domini és suficient per reduir notablement el *domain shift*. A més, el fet que els resultats finals siguin molt similars entre el model basat en n-grams de paraula amb ajust del llindar i el model final després de l'adaptació suggereix que la millora principal prové de la incorporació de dades representatives del nou domini més que de la complexitat del model utilitzat.

A partir d'aquests experiments, es selecciona com a model final la configuració que combina n-grams de paraula i caràcter juntament amb l'ajust del llindar de decisió, amb un F1-macro de 0.9222 en el dataset principal i de 0.6913 en Jigsaw. Aquesta decisió es planteja com un problema multicriteri, on es prioritza la robustesa *out-of-domain* mantenint al mateix temps un rendiment elevat *in-domain*. En aquest treball s'assumeix que, en una aplicació real, el domini dels textos pot variar respecte al conjunt d'entrenament i, per tant, es considera més adequat optimitzar un compromís entre rendiment en el domini original i capacitat de generalització, fins i tot si això implica una lleugera reducció de l'F1-macro en el dataset principal. Tot i aquesta millora, els resultats obtinguts en Jigsaw mostren que el model encara tendeix a sobrepredir la classe tòxica, especialment en textos discursius o argumentatius. En una aplicació real de moderació automàtica, aquest comportament podria traduir-se en problemes d'*overblocking*, és a dir, en el marcat o bloqueig incorrecte de contingut legítim.

L'anàlisi qualitativa dels errors ha permès entendre millor el comportament dels models i identificar tres fonts principals de limitacions. En primer lloc, s'observen errors relacionats amb polisèmia i dependència excessiva de patrons lèxics locals, on certes paraules potencialment ofensives poden aparèixer en contextos completament neutres i continuar dominant la classificació. En segon lloc, apareixen problemes de cobertura de vocabulari i *out-of-vocabulary*, especialment en l'escenari *out-of-domain*, on insults poc freqüents, variants ortogràfiques o textos en altres idiomes dificulten la detecció correcta de toxicitat. Aquest comportament ajuda també a explicar per què els n-grams de caràcter milloren la generalització, ja que permeten capturar patrons sublèxics i similituds parcials entre paraules no observades durant l'entrenament. En tercer lloc, els textos més llargs i argumentatius del dataset Jigsaw introdueixen dificultats addicionals, ja que les contribucions de termes ofensius poden quedar diluïdes dins del conjunt del text i el model tendeix a interpretar desacords o discussions formals com a toxicitat.

Finalment, el sarcasme s'ha utilitzat com a conjunt de prova d'estrès per analitzar el comportament del model davant de llenguatge no literal. Els resultats mostren que els textos sarcàstics presenten una taxa de prediccions tòxiques més elevada que els textos no sarcàstics, suggerint que el sarcasme actua com un factor que incrementa la propensió del model a activar prediccions tòxiques. L'anàlisi qualitativa permet distingir dos comportaments diferenciats del model davant del sarcasme. En un primer grup, els textos contenen lèxic ofensiu explícit, de manera que el model activa prediccions tòxiques degut a la seva forta dependència de paraules amb pesos elevats. En un segon grup, els textos no contenen insults directes i la classificació com a tòxics sembla relacionada amb la incapacitat dels models basats en n-grams per interpretar senyals pragmàtics, ironia o significats no literals. Això suggereix que aquests models capturen principalment correlacions lèxiques superficials però no disposen de mecanismes per entendre adequadament la intenció comunicativa o el context global del missatge.

A més, la prova d'estrès addicional amb un dataset de sarcasme en castellà ha reproduït el mateix patró observat en anglès: els textos sarcàstics presenten una taxa de prediccions tòxiques superior als no sarcàstics. Tot i que aquest experiment no pretén avaluar les capacitats multilingües del model, els resultats reforcen la idea que el sarcasme constitueix una font de confusió per als models basats en n-grams.

En conclusió, aquest treball mostra que els models clàssics basats en n-grams continuen sent eines eficients, competitives i altament interpretables per a la detecció de toxicitat en textos curts. Tanmateix, els resultats també evidencien que la generalització entre dominis continua sent limitada i que aquests models presenten dificultats davant de fenòmens lingüístics complexos, com la polisèmia o el sarcasme. Per aquest motiu, la seva aplicació en contextos reals requereix tenir en compte tant el domini dels textos com els criteris d'etiquetatge utilitzats.

De cara a possibles continuacions del treball, es podria comparar el comportament dels models clàssics amb arquitectures de *deep learning*, especialment amb arquitectures contextuals com BERT, que poden representar millor el significat global dels textos i les dependències entre paraules. També seria interessant estudiar tècniques d'adaptació de domini i entrenar els models amb dades procedents de diferents plataformes. A més, es podria aprofundir en l'anàlisi de fenòmens pragmàtics, com el sarcasme i la ironia, mitjançant conjunts de dades que incloguessin simultàniament etiquetes de sarcasme i toxicitat.

Referències

[1] Samoshyn, A. [mrmorj]. (s.d.). Hate Speech and Offensive Language Dataset. Kaggle. `https://www.kaggle.com/datasets/mrmorj/hate-speech-and-offensive-language-dataset`

[2] Peller, J. [julian3833]. (s.d.). Jigsaw Toxic Comment Classification Challenge. Kaggle. `https://www.kaggle.com/datasets/julian3833/jigsaw-toxic-comment-classification-challenge`

[3] Hämäläinen, M. [mikahama]. (s.d.). The Best Sarcasm Annotated Dataset in Spanish. Kaggle. `https://www.kaggle.com/datasets/mikahama/the-best-sarcasm-annotated-dataset-in-spanish`

[4] Ofer, D. [danofer]. (s.d.). Balanced Sarcasm Dataset. Kaggle. `https://www.kaggle.com/datasets/danofer/sarcasm?select=train-balanced-sarcasm.csv`

[5] Davidson, T., Warmsley, D., Macy, M., & Weber, I. (2017). *Automated Hate Speech Detection and the Problem of Offensive Language*. Proceedings of the International AAAI Conference on Web and Social Media (ICWSM). `https://arxiv.org/abs/1703.04009`

[6] Gaydhani, A., Doma, V., Kendre, S., & Bhagwat, L. (2018). *Detecting Hate Speech and Offensive Language on Twitter using Machine Learning: An N-gram and TFIDF based Approach.* `https://arxiv.org/abs/1809.08651`

[7] Wei, B., Li, J., Gupta, A., Umair, H., Vovor, A., i Durzynski, N. (2021). *Offensive Language and Hate Speech Detection with Deep Learning and Transfer Learning.* `https://arxiv.org/abs/2108.03305`

[8] Jessica, A., Sugiarto, M., Jerry, Achmad, S., & Sutoyo, R. (2024). *A Hybrid Deep Learning Techniques Using BERT and CNN for Toxic Comments Classification*. Bina Nusantara University.
https://www.researchgate.net/publication/387113558_A_Hybrid_Deep_Learning_Techniques_Using_BERT_and_CNN_for_Toxic_Comments_Classification