UAB
Universitat Autònoma de Barcelona

Facultat de Ciències

Detecció de Llenguatge Tòxic en Textos Curts

Treball de Fi de Grau

Maria Muñoz Cabestany

Grau en Matemàtica Computacional i Analítica de Dades

Tutor: Jordi González Sabaté

3 de juliol de 2026

UAB
Universitat Autònoma de Barcelona

Context i motivació

1 PROBLEMA SOCIAL

Moderar manualment grans volums de comentaris no és escalable.

2 REPTE LINGÜÍSTIC

La toxicitat pot dependre del context, del domini, dels criteris d'etiquetatge i del sarcasme.

3 ENFOCAMENT

Models clàssics i interpretables per estudiar rendiment, generalització i errors.

UAB
Universitat Autònoma
de Barcelona

Objectiu

Desenvolupar i analitzar un sistema de classificació binària de textos curts per detectar llenguatge tòxic

UAB
Universitat Autònoma de Barcelona

Datasets

DATASET PRINCIPAL

Tweets

Train + test in-domain

Etiquetatge

hate + offensive = tòxic (1)
neither = no tòxic (0)

JIGSAW

Textos de Wikipedia

Test out-of-domain
No entrenament principal

Etiquetatge

toxic o severe_toxic = tòxic (1)
en cas contrari = no tòxic (0)

SARCASME EN

SARCASME ES

Prova d'estrès

No etiquetats com a tòxics.
Toxic prediction rate

UAB
Universitat Autònoma de Barcelona

Metodologia

Divisió conjunt de dades principal
80% entrenament, 20% test

→

Preprocessament del text

→

Vectorització del text

REPRESENTACIÓ

- Bag-of-Words
- TF-IDF

N-grams de paraula (1,2)

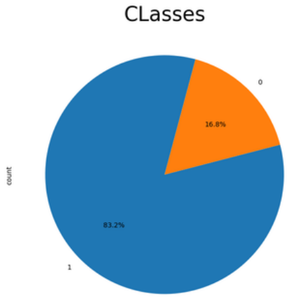
UAB
Universitat Autònoma de Barcelona

Metodologia

Models ML clàssics → Cerca d'hiperparàmetres (validació creuada 5-fold) → Avaluació in-domain → Avaluació out-of-domain

MODELS

- Logistic Regression
- Linear SVM
- Multinomial NB
- Complement NB
- Bernoulli NB



MÈTRICA

F1-macro : dades desbalancejades

UAB
Universitat Autònoma de Barcelona

Resultats base del dataset principal

F1-macro en test in-domain; hiperparàmetres ajustats amb 5-fold cross-validation

Model	BoW	TF-IDF	BOW (tuned)	TF-IDF (tuned)
Logistic regression	0.9222	*0.8750*	*0.922*	*0.9129*
Linear SVM	0.9060	0.9150	**0.9263**	0.9150
Multinomial NB	0.8809	0.7426	0.8809	0.8205
Complement NB	0.8832	0.8742	0.8822	0.8742
Bernoulli NB	0.8755	0.8755	0.8884	0.8884



MILLOR BASELINE

BoW (tuned)
+
Linear SVM

F1-macro = 0.9263

UAB
Universitat Autònoma de Barcelona

Resultats base del dataset Jigsaw

Model	BoW	TF-IDF
Logistic regression	*0.6521*	0.5000
Linear SVM	**0.6431**	0.5296
Multinomial NB	0.6110	0.3777
Complement NB	**0.6917**	0.5874
Bernoulli NB	0.6216	0.6216

DOMAIN SHIFT

Tweets
vs
Wikipedia

El millor model in-domain no és necessàriament el millor out-of-domain

UAB
Universitat Autònoma de Barcelona

Anàlisi definició de toxicitat

Comparació de criteris d'etiquetatge a Jigsaw

Representació (model Linear SVM)	Binarització	F1-macro ↑ (Jigsaw)
BoW	toxic OR severe toxic	*0.6431*
BoW	OR qualsevol etiqueta	**0.6501**
TF-IDF	toxic OR severe toxic	0.5296
TF-IDF	OR qualsevol etiqueta	**0.5370**

Idea clau

Diferències entre **definició de toxicitat** i els **criteris d'etiquetatge.**

Decisió metodològica

Es manté la definició original

UAB
Universitat Autònoma de Barcelona

Millores

PUNT DE PARTIDA

Linear SVM (tuned) + n-grams de paraula (WORD)

- N-grams: (1,2)

Configuració	F1-macro ↑ (Dataset principal)	F1-macro ↑ (Jigsaw)
WORD (baseline)	0.9263	*0.6431*

MILLORES

PESOS DE CLASSE

Compensen el desbalanceig.
No canvia el comportament del model.

UAB
Universitat Autònoma de Barcelona

PUNT DE PARTIDA

Configuració	F1-macro ↑ (Dataset principal)	F1-macro ↑ (Jigsaw)
WORD (baseline)	0.9263	*0.6431*

Millores

THRESHOLD

Millora el rendiment out-of-domain sense perdre rendiment in-domain

Configuració	F1-macro ↑ (Dataset principal)	F1-macro ↑ (Jigsaw)
WORD + threshold	*0.9269*	0.6789

N-GRAMS DE CARÀCTER (3-5)

- Seqüències de 3 a 5 caràcters
- Millora la robustesa out-of-domain
- Petita pèrdua de rendiment in-domain

Configuració	F1-macro ↑ (Dataset principal)	F1-macro ↑ (Jigsaw)
CHAR	0.9149	*0.6698*

UAB
Universitat Autònoma de Barcelona

Millores

PUNT DE PARTIDA

Configuració	F1-macro ↑ (Dataset principal)	F1-macro ↑ (Jigsaw)
WORD (baseline)	0.9263	*0.6431*

COMBINACIÓ

Millor compromís global

Configuració	F1-macro ↑ (Dataset principal)	F1-macro ↑ (Jigsaw)
WORD + CHAR	*0.9168*	*0.6722*
WORD + CHAR + THRESHOLD	0.9222	*0.6913*

ELIMINACIÓ DE STOPWORDS

- Millora Jigsaw
- Baixada lleu al dataset principal
- Pèrdua de context

Configuració	F1-macro ↑ (Dataset principal)	F1-macro ↑ (Jigsaw)
Sense stopwords	0.9172	0.7242

UAB
Universitat Autònoma de Barcelona

Adaptació de domini amb Jigsaw

(experiment controlat)

S'incorpora un **10% del dataset Jigsaw** al conjunt d'entrenament

Configuració	F1-macro ↑ (Dataset principal)	F1-macro ↑ (Jigsaw)
WORD + threshold	0.9269	*0.6789*
WORD + CHAR + threshold	0.9222	0.6913
WORD + threshold + adaptació 10%	0.9314	0.8346
WORD + CHAR + threshold + adaptació 10%	0.9253	0.8367



L'adaptació redueix el domain shift. **No és el model final.**

UAB
Universitat Autònoma de Barcelona

Model final seleccionat

Configuració	**F1-macro ↑ (Dataset principal)**	**F1-macro ↑ (Jigsaw)**
WORD (baseline)	0.9263	*0.6431*
WORD + CHAR + THRESHOLD	0.9222	*0.6913*

DECISIÓ MULTICRITERI

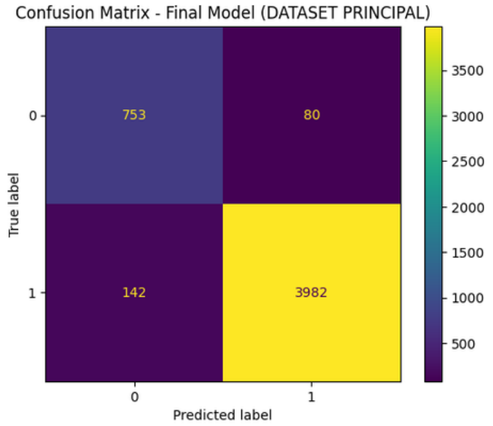
Es busca un compromís entre rendiment in-domain i generalització out-of-domain.

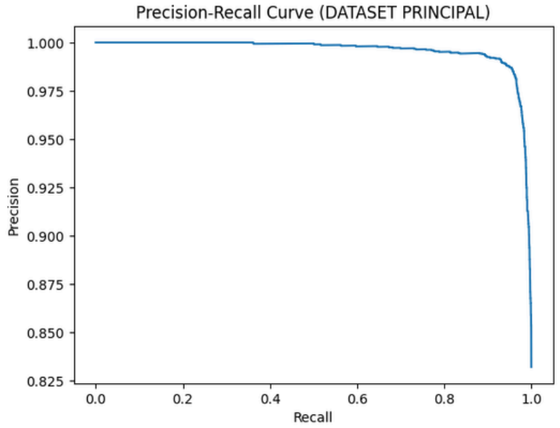
Model final: **WORD + CHAR + threshold**

UAB
Universitat Autònoma de Barcelona

Anàlisi model final

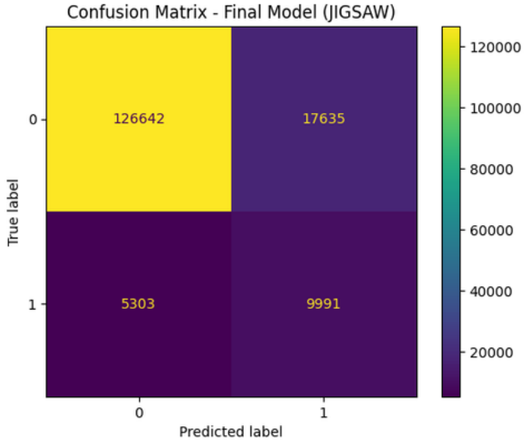
DATASET PRINCIPAL

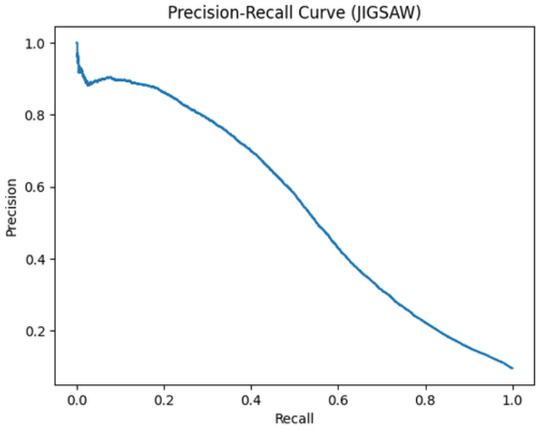




Classe	Precision	Recall
No tòxic (0)	0.84	0.90
Tòxic (1)	0.98	0.97

DATASET JIGSAW





Classe	Precision	Recall
No tòxic (0)	0.96	0.88
Tòxic (1)	0.36	0.65

UAB
Universitat Autònoma
de Barcelona

Anàlisi qualitativa

UAB
Universitat Autònoma de Barcelona

Interpretabilitat amb n-grams

Com s'interpreten les decisions del model?

Interpretació parcial (n-grams de paraula)

No tòxic — 0 — **Tòxic**

n-grams	Coef.
hoe hoe	*-0.2396*
night	-0.1508
trash	-0.1213
shy	-0.1052

- Paraules neutres
- Llenguatge informal
- Context ambigu

- Insults explícits
- Bigrams ofensius
- Vocabulari discriminatori

n-grams	Coef.
fag	*0.4561*
hoe	0.3406
ass	0.2679
white trash	0.1666

UAB
Universitat Autònoma de Barcelona

Anàlisi d'errors: factors principals

1 ARTEFACTES / POLISÈMIA

Paraules amb doble significat

"Remember Dad running a rotary **hoe** over corn after a freeze."

2 COBERTURA DE VOCABULARI

Insults out-of-vocabulary

"THE GUY ABOVE ME IS A **WANKER**!!"

3 LONGITUD I ESTIL

Textos llargs i discursius

"I just want to resolve this issue (...) or at least an on-line way to find someone who can deal with this."

UAB
Universitat Autònoma
de Barcelona

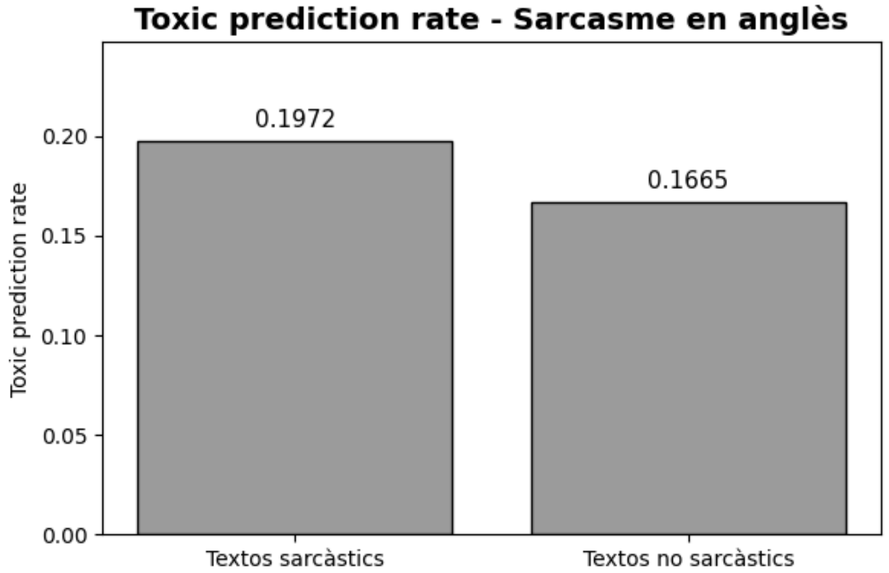
Sarcasme com a prova d'estrès

Hipòtesi

El sarcasme pot generar més prediccions tòxiques perquè el model es basa en patrons lèxics i no interpreta bé la intenció irònica

UAB
Universitat Autònoma de Barcelona

Dataset sarcasme en anglès



El sarcasme incrementa la propensió del model a activar la classe tòxica

UAB
Universitat Autònoma de Barcelona

Dataset sarcasme en anglès

Sarcasme amb lèxic ofensiu explícit

- “Fuck you too!”
- “Do I look like I give a shit granny?”

Aquí la predicció tòxica és esperable.

Sarcasme sense insults explícits

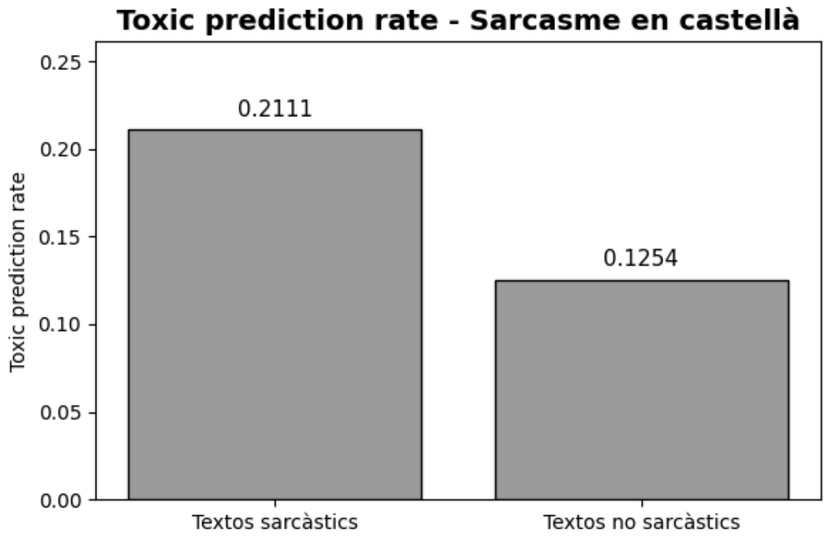
- “I’m sure it was a white guy”
- “That’s about the percentage of all white men in America still voting”

Aquí es veu la limitació pragmàtica del model.

UAB
Universitat Autònoma de Barcelona

Prova addicional d'estrès

Dataset sarcasme en castellà



Patró més marcat.
Interpretació limitada: l'efecte combina sarcasme i canvi de llengua.

UAB
Universitat Autònoma de Barcelona

Conclusions

1. **BoW + Linear SVM** millor baseline
2. Bon rendiment, però **generalització limitada**
3. Millora amb **n-gram de caràcter** i **llindar de decisió**
4. Poques dades del **nou domini** milloren la generalització
5. Anàlisi d'errors identifica **patrons** útils
6. El **sarcasme** continua sent un **repte**

UAB
Universitat Autònoma
de Barcelona

Moltes gràcies per la vostra atenció.